UNIVERSIDAD DE BURGOS
ESCUELA POLITÉCNICA SUPERIOR
Grado en Ingeniería Informática

TFG del Grado en Ingeniería Informática

Urban Street Mapping Transfer

Presentado por Mario Hurtado Ubierna
en Universidad de Burgos — 9 de septiembre de 2023
Tutor: Virginia Ahedo García y Jesús Manuel Maudes Raedo

UNIVERSIDAD DE BURGOS
ESCUELA POLITÉCNICA SUPERIOR
Grado en Ingeniería Informática

Dña. Virginia Ahedo, profesora del departamento de Ingeniería de Organización, área de Organización de Empresas y D. Jesús Manuel Maudes, profesor del departamento de Ingeniería Informática, área de Lenguajes y Sistemas Informáticos.

Expone:

Que el alumno D. Mario Hurtado Ubierna, con DNI 71365182T, ha realizado el Trabajo final de Grado en Ingeniería Informática titulado « >.

Y que dicho trabajo ha sido realizado por el alumno bajo la dirección del que suscribe, en virtud de lo cual se autoriza su presentación y defensa.

En Burgos, 9 de septiembre de 2023

Vº. Bº. del Tutor:	Vº. Bº. del co-tutor:
Dña. Virginia Ahedo	D. Jesús Manuel Maudes

Resumen

Uno de los principales factores que considerar cuando se busca abrir un nuevo negocio es la localización. Esto plantea un problema conocido como el *Location Problem*, el cual busca encontrar la ubicación más adecuada para una determinada categoría comercial pueda reportar más beneficios. En el caso del proyecto se aplicará al *retailing*, es decir, a tiendas minoristas.

Existen distintas aproximaciones a este problema, en este proyecto se aplicará un enfoque desde la ciencia de redes, teniendo en consideración las distintas categorías comerciales y otros servicios en una serie de ciudades con el objetivo de crear un sistema de recomendación con capacidad de ofrecer propuestas de comercios, así como de ubicaciones dada una categoría comercial en concreto. Para ello se calcularán las relaciones de atracción y repulsión entre las distintas categorías teniendo en cuenta la distribución geográfica de estas.

Para lograr lo anterior se utilizarán datos extraídos de una API de geolocalización de un proyecto conocido como *OpenStreetMap* de uso libre, así como,*Neo4j*, que forma parte de un nuevo paradigma conocido como la orientación a grafos en el contexto de las bases de datos.

Además de contemplar recomendaciones a nivel local, también se empleará la transferencia de información entre ciudades, permitiendo utilizar la información de una ciudad sobre otra diferente, evitando de esta forma un nuevo proceso de extracción de información para esa segunda ciudad. Con este objetivo se creará también un modelo de inteligencia artificial que integre los datos de todas las ciudades.

Para facilitar el uso de la herramienta de este proyecto, se desarrollará una aplicación web sencilla que permita a los usuarios obtener recomendaciones basadas la ubicación o en la categoría comercial.

Descriptores

Ciencia de redes, sistema de recomendación, comercio minorista, *machine learning*, web, transferencia de conocimiento, API de geolocalización, base de datos de grafos.

Abstract

One of the main factors to consider when looking to open a new business is location. This poses a problem known as the *Location Problem*, which seeks to find the most suitable location for a given business category that can bring the most profit. In the case of this project, it will be applied to retailing, i.e. retail stores.

There are different approaches to this problem, in this project a network science approach will be applied, taking into consideration the different commercial categories and other services in a series of cities with the objective of creating a recommendation system with the capacity to offer proposals of stores, as well as locations given a specific commercial category. For this purpose, the attraction and repulsion relationships between the different categories will be calculated, taking into account their geographical distribution.

To achieve the above, data extracted from a geolocation API of a project known as OpenStreetMap will be used, as well as Neo4j, which is part of a new paradigm known as graph orientation in the context of databases.

In addition to contemplating recommendations at the local level, the transfer of information between cities will also be used, allowing the use of information from one city on a different one, thus avoiding a new information extraction process for that second city. For this purpose, an artificial intelligence model that integrates data from all cities will also be created.

To facilitate the use of the tool of this project, a simple web application will be developed to allow users to obtain recommendations based on location or commercial category.

Keywords

Network science, recommendation system, retailing, machine learning, web, knowledge transfer, geolocation API, graph database

Índice general

Índice de figuras

Índice de tablas

Introducción

El conocido como *Retail Location Problem* consiste en un problema al que se enfrentan los negocios a la hora de elegir una ubicación donde abrir un nuevo establecimiento. Un correcto emplazamiento puede incrementar enormemente el rendimiento del negocio, proporcionando ventajas que la competencia difícilmente puede imitar. Esto puede suponer la diferencia entre el éxito o el fracaso

Urban Street Mapping Transfer se trata de un de un proyecto que busca ofrecer soluciones para este problema. La técnica que se utilizará para ello consiste en el análisis de la estructura comercial de cada ciudad mediante el uso de conceptos propios de la ciencia de redes así como de distintos métodos matemáticos y estadísticos que nos permitan estimar qué ubicaciones pueden ser más provechosas para un negocio. También se emplearán modelos de inteligencia artificial para integrar los resultados del análisis en un sistema de recomendación.

Además de lo anterior se utilizará *knowledge transfer*, que permitirá utilizar datos de unas ciudades para poder realizar recomendaciones sobre otras. Todo lo anterior se realizará haciendo uso de una herramienta de gestión de bases de datos orientada a grafos, Neo4j.

Todo lo anterior supone un gran trabajo de investigación, tanto de aprendizaje de herramientas de nuevos paradigmas, de extracción de información y de aplicación de las diversas técnicas que se proponen en el trabajo.

Objetivos del proyecto

Este proyecto tiene como objetivo principal la creación de recomendaciones de categorías comerciales dadas ubicaciones, de forma que se pueda elegir mejor la localización de un determinado establecimiento comercial. Para ello se utilizarán distintos índices de calidad propuestos para este problema así como su uso combinado mediante un modelo de inteligencia artificial destinado a problemas de clasificación. Para facilitar el uso de la herramienta se diseñará una aplicación web sencilla que permita hacer las recomendaciones a un usuario.

Los objetivos para llevar a cabo el proyecto son los siguientes:

1. Obtención de establecimientos comerciales y sus respectivas categorías para un grupo de ciudades mediante una API de geolocalización.

2. Uso de una base de datos orientada a grafos donde almacenar las ubicaciones comerciales de forma que podamos operar sobre ella como se haría en una red.

3. Modelado de la estructura comercial de cada ciudad mediante redes complejas y análisis de las interacciones entre las distintas categorías.

4. Cálculo de distintos índices de calidad de acuerdo a distintas aproximaciones para utilizarlos en la emisión de recomendaciones.

5. Uso de transferencia de conocimiento entre la estructura comercial de distintas ciudades usando los índices de calidad de una ciudad para emitir recomendaciones sobre otra distinta.

6. Creación de distintos sistemas de recomendación, al menos uno de los cuales agregará los distintos índices de calidad de diferentes ciudades mediante algoritmos de *Machine Learning*.

7. Creación de una aplicación web con objetivo de facilitar el uso de la herramienta.

Conceptos teóricos

La cuestión que se busca abordar con este proyecto es el *Retail Location Problem*. Este consiste en la elección de la ubicación en la que colocar una nueva tienda de forma que esta le aporte el máximo beneficio posible. Para abordar esto se emplearán técnicas propias de la ciencia de redes, el aprendizaje automático y el conocido como *knowledge transfer*.

3.1. *Retail Location Problem*

El conocido como «Retail Location Problem» trata de un problema enfrentado por las empresas pertenecientes al comercio minorista al elegir una ubicación donde empezar un nuevo negocio. La ubicación, lejos de ser un factor carente de importancia puede marcar la diferencia entre el éxito o el fracaso del comercio. Un negocio adecuadamente posicionado cuenta con ventajas sobre la competencia que pueden hacer aumentar significativamente su rendimiento sobre el resto [10, 31].

La elección de la ubicación puede hacerse ateniendo a distintos factores, logísticos, poblacionales, fiscales, entre otros.

En este proyecto, se emitirán recomendaciones basándose en el ecosistema que rodea a una determinada ubicación, teniendo en cuenta cómo complementan los distintos comercios cercanos al hipotético nuevo negocio. Todo ello se abordará desde el enfoque de Teoría de Redes [33], modelando los ecosistemas comerciales como redes complejas, y analizándolas con las distintas herramientas pertinentes.

3.2. Teoría de grafos

Los grafos son abstracciones matemáticas compuestas por dos elementos [40]:

- V: Vértices o nodos. Suponen la entidad más básica del grafo, pudiendo representar distintos conceptos.
- E: Enlaces o aristas. Representan las relaciones entre los distintos nodos de un grafo.

Dada su naturaleza, los grafos han sido usados habitualmente para modelar relaciones entre elementos.

Los nodos, además de constituir el elemento más básico, pueden presentar atributos,los cuales indican distintas casuísticas, tales como, por ejemplo, la pertenencia a un determinado grupo.

Existen distintos tipos en función de como se modelen las relaciones entre objetos. Si las relaciones no cuentan con dirección alguna se les conoce como no dirigidos, si existe alguna restricción en las direcciones con las que se recorren los enlaces entonces se trata de un grafo dirigido; y en caso de permitir múltiples enlaces entre cada par de nodos se trataría de un multigrafo. También pueden presentar una ponderación en los enlaces entre nodos, siendo de esta forma un grafo pesado [40].

Modelos nulos

En el ámbito de las matemáticas y la teoría de grafos un modelo nulo se trata de un modelo con una generación aleatoria en alguno de sus aspectos [42]. Los modelos nulos sirven como referencia, ya que nos permiten conocer cuáles serían los patrones que encontraríamos si el fenómeno bajo consideración se hubiera generado de manera aleatoria, al azar. De esta forma se puede extraer ciertas características distintivas de los grafos sujetos a análisis.

En nuestro proyecto, los modelos nulos servirán como referencia para identificar aquellas relaciones entre comercios que son estadísticamente significativas.

3.3. Ciencia de Redes

La ciencia de redes se trata de un campo de investigación multidisciplinar que bebe de distintos ámbitos tales como las matemáticas, la estadística, la minería de datos, entre otros. Utiliza los conocimientos que la teoría de grafos provee para representar elementos y relaciones de la realidad y de esta forma ser capaces de estudiar y analizar sistemas complejos. Los grafos utilizados por esta rama de conocimiento se suelen conocer como redes [33].

Además de basarse en los conceptos de la teoría de grafos, también aplica técnicas propias de la informática y el «Machine Learning» para facilitar las labores de análisis de redes. Algunos ejemplos de aplicación de estas técnicas podrían ser la predicción de posibles enlaces entre nodos, detección de comunidades o la clasificación de nodos en distintas categorías.

En los últimos años ha obtenido gran relevancia al aplicarse a ámbitos como las redes sociales, de transporte, de transmisión de enfermedades, entre otros. En el caso de este trabajo, se aplicará para modelar la estructura comercial de las distintas ciudades con el objetivo de hacer recomendaciones en base a la ubicación para determinados negocios.

3.4. Técnicas

Con el objetivo de extraer y analizar la estructura comercial de una ciudad, en la literatura se han propuesto distintos métodos basados en Teoría de Redes, los cuales se diferencian en sus hipótesis subyacentes. En última instancia, los distintos enfoques tienen distintos modelos nulos contra los que chequean la significación estadística de las interacciones comerciales (tanto atractivas como repulsivas). Nótese, que cada método nos permite posteriormente calcular índices de calidad para cada ubicación, los cuales nos dan una idea de la idoneidad de la localización para cada categoría comercial [10, 31]. Estos nos proveen coeficientes entre las distintas categorías que nos permitirán extraer las relaciones de afinidad y repulsión; además de posteriormente permitirnos los cálculos de los índices de calidad para cada ubicación, pudiendo realizar con ellos las recomendaciones que buscamos en este trabajo.

Se trata de los siguientes:

- Jensen
- *Permutation*

- *Rewiring*

Antes de poder aplicar estos métodos será necesario contar con una representación en forma de red de la estructura comercial de la ciudad [10, 31]. Los nodos de este grafo representarán cada una de las ubicaciones comerciales. En cuanto a las relaciones, estas se crearan en base a la proximidad espacial entre nodos. Para esto se tomará una distancia de 100 metros como máximo para la creación de un enlace i.e., se creará un enlace entre dos nodos (locales comerciales) si se encuentran a una distancia menor o igual que 100 m. (Distancia geodésica).

A continuación, se hará una breve descripción de cada uno de estos métodos. Para ello, utilizaremos la siguiente nomenclatura [10, 31].

- T: Conjunto de todas las distintas ubicaciones.
- A, B: Conjuntos de ubicaciones de determinadas categorías.
- null_model: Obtenido a partir de las simulaciones de Monte Carlo de *Permutation* y *Rewiring*.
- $N_s(p, r)$: Tamaño del conjunto de ubicaciones de categoría s en una proximidad de r metros.

Jensen

Jensen propone unos coeficientes de interacción entre categorías [14]. Este método puede obtener tanto las relaciones de atracción como de repulsión entre categorías comerciales. Las primeras serán aquellas con un valor por encima de 1, y las segundas aquellas en las que esté por debajo de 1.

El cálculo de estos coeficientes es distinto cuando se trata de una categoría sobre sí misma con respecto a una categoría sobre otra distinta.

$$\text{Intracategoría: } M_{\text{AA}} = \frac{|T| - 1}{|A|(|A| - 1)} \sum_{a \in A} \frac{N_A(a, r)}{N_T(a, r)}$$

$$\text{Intercategoría: } M_{\text{AB}} = \frac{|T| - |A|}{|A||B|} \sum_{a \in A} \frac{N_B(a, r)}{N_T(a, r) - N_A(a, r)}$$

El cálculo de estos coeficientes llevará a la obtención de una matriz de interacciones que podrá ser utilizada para posteriores cálculos [14].

El método de Jensen presenta algunos problemas:

- Tiendas aisladas: Si alguna tienda se encuentra aislada del resto esto conlleva a una indeterminación $\frac{0}{0}$ en el cálculo de los coeficientes.
- Función logarítmica: A la hora de aplicar los coeficientes de Jensen se emplea su valor logarítmico, haciendo que se comporte de forma asimétrica para valores positivos y negativos. Además, en caso de que el coeficiente sea 0 hace que su valor sea $-\infty$.

Dados estos problemas se proponen otros 2 métodos alternativos al de Jensen.

Permutation

El método *Permutation* requiere de la aplicación de simulaciones de Monte Carlo [35] con modelos nulos sobre la red [10, 31]. En este caso se crearán redes aleatorias, pero con la restricción de que se mantendrá la estructura real de la red, permutándose aleatoriamente las categorías asociadas a cada nodo. La hipótesis subyacente es la siguiente: se mantiene la estructural comercial global (la ubicación de los emplazamientos comerciales) pero no se mantiene el ecosistema local, ya que se permutan las categorías comerciales.

De cada simulación se obtendrá el valor de interacción entre categorías, para posteriormente obtener la media y la desviación típica de los resultados de las simulaciones [10, 31].

Con ello se podrá obtener el Z-Score para cada par de categorías, con un funcionamiento análogo a los coeficiente de Jensen. Se obtendrá una matriz simétrica con ellos.

$$Z_{AB} = \frac{x_{AB} - \overline{x_{AB}^{null\_model}}}{s_{AB}^{null\_model}}$$

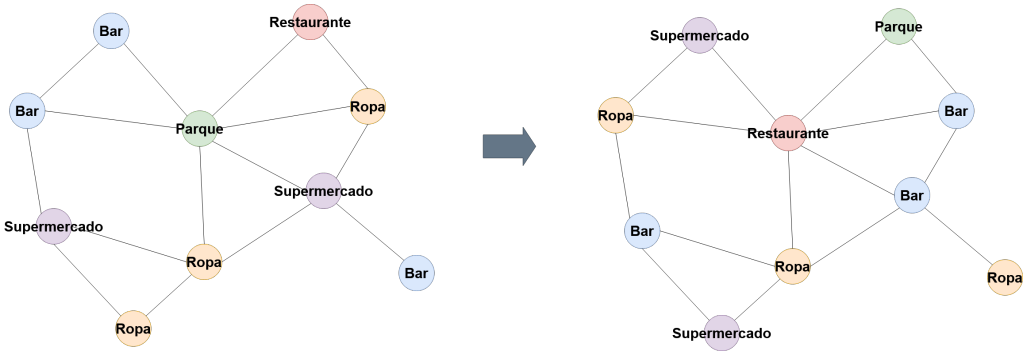

Figura 3.1: Ejemplo del método *Permutation*

Rewiring

Rewiring se trata de un método similar al anterior, también está basado en la generación de modelos nulos con simulaciones de Monte Carlo [35]. La diferencia entre este y el anterior está en las restricciones. En este la categoría comercial es mantenida en cada uno de los nodos, mientras que los enlaces entre nodos son aleatorizados, con la única restricción de que se debe mantener el grado que los nodos poseían en la red original [10, 31]. La hipótesis bajo Rewiring es que al mantener el grado, estamos preservando la estructura local que se genera en torno a un determinado comercio de una determinada categoría.

Al igual que en el anterior se obtendrá una matriz con los Z-Score por pares de categorías.

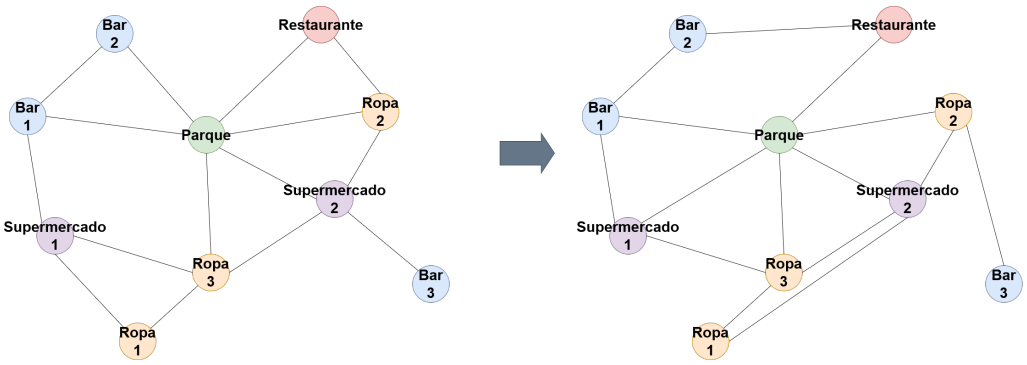

Figura 3.2: Ejemplo del método *Rewiring*

3.5. Índices de calidad

Con los coeficientes de interacción entre categorías de la anterior sección se pueden obtener los llamados *quality indices* o índices de calidad [10, 14, 31]. Dichos índices cuantifican numéricamente la idoneidad de una localización para una determinada categoría comercial. En el caso de Jensen se aplica el valor del logaritmo del coeficiente, es decir, $a_{ij} = log(M_{ij})$, mientras que en el caso de *Permutation* y *Rewiring* se utilizará el propio Z-Score para esas categorías, $a_{ij} = Z_{ij}$ [10].

$$Q_i(x,y) \equiv \sum_{j=1}^{N} a_{ij}(nei_{ij}(x,y) - \overline{nei_{ij}})$$

- a_{ij}: Interacción de la matriz de coeficientes entre categorías i y j.
- N: Número total de categorías.
- $nei_{ij}(x,y)$: Número de negocios vecinos con categoría j en torno a ubicación (x,y).
- $\overline{nei_{ij}}$: Promedio de vecinos de la categoría j que tienen los nodos de categoría i.

Con esto se obtendría la adecuación de una ubicación (x,y) con la categoría comercial i. Si se parte de un conjunto predefinido de categorías comerciales se puede encontrar el negocio más adecuado para una ubicación (x,y) calculando los índices de calidad para todas las categorías, siendo el más apropiado aquel con mayor valor de Q_i [10, 14].

Índices *Raw*

La idea que subyace a los índices de calidad de la sección anterior es la de que una ubicación que se asemeje a la ubicación promedio de todas las tiendas minoristas de esa categoría dentro de la ciudad, puede ser un buen local para otra tienda de esa categoría [14]. Lo anterior se manifiesta al sustraer el valor promedio para cada categoría $\overline{nei_{ij}}$ en el cálculo de los índices de calidad. Alternativamente se proponen unos nuevos que no tienen en consideración los valores medios [10]. Su cálculo es el siguiente:

$$Q_i(x,y) \equiv \sum_{j=1}^{N} a_{ij}(nei_{ij}(x,y))$$

Mean Reciprocal Rank

Los índices de calidad nos proporcionan una serie de categorías comerciales ordenadas en función de la adecuación de cada una. Para poder evaluar la eficiencia de cada índice se emplea la medida conocida como *Mean Reciprocal Rank* [38]. Esta se suele emplear en sistemas de recomendación para evaluar su rendimiento usando la posición que ocupa la categoría real sobre el *ranking* provisto, en este caso, por los índices de calidad [10]. Sigue la siguiente formula:

$$MRR = \frac{1}{|Q|}\sum_{i=1}^{|Q|}\frac{1}{rank_i}$$

- Q: Conjunto de ubicaciones con categoría conocida.
- $rank_i$: Posición que ocupa la categoría real de la ubicación en el *ranking* ofrecido por un índice de calidad.

Uso combinado de índices de calidad

Si bien el uso simple de los índices de calidad ya es suficiente para obtener recomendaciones, puede darse la situación en que estas difieran dependiendo del método utilizado para obtener los índices. Si bien podemos ver qué método es más eficaz utilizando el MRR y decantarnos por uno o por otro, puede darse el caso de que difieran por estar capturando información diferente. Por este motivo, puede ser interesante hacer uso de todos ellos conjuntamente, agregándolos mediante un modelo de *machine learning*, para que este pueda explotar todos los aspectos complementarios de los mismos. [10].

Para poder entrenar el modelo se debe contar primero con un conjunto de datos. Este lo podremos construir con una serie de ubicaciones de las que conozcamos su categoría real, siendo esta la etiqueta a predecir. Los predictores los constituirán los valores de los índices de calidad de cada ubicación obtenidos para cada método y categoría.

El modelo entrenado podrá realizar las funciones de sistema de recomendación, pudiendo a su vez ser evaluado usando el MRR.

En este trabajo se empleará un *Random Forest* [43], clasificador de la familia de los *ensembles*. El uso de un modelo de esta familia es debido a las ventajas que estos poseen frente a los modelos simples, ofreciendo mejor

rendimiento y versatilidad [12]. Estos además presentan un buen equilibrio entre *bias* y varianza, puesto que con sus múltiples árboles es capaz de reducir la varianza mientras que mantiene su capacidad de detectar patrones complejos en los datos manteniendo un *bias* bajo.

3.6. *Knowledge Transfer*

El conocido como *Transfer Learning* [44] se trata de una técnica propia del aprendizaje automático que consiste en utilizar conocimiento obtenido previamente para resolver nuevos problemas similares. Esto permite mejorar el rendimiento ya que se cuentan con datos previos que pueden ser reutilizados.

En el caso de este trabajo el *Knowledge Transfer* aplicará calculando los índices de calidad de una ciudad utilizando la matriz de interacciones de los distintos métodos de otra [10]. A su vez estos pueden ser utilizados de forma combinada mediante un modelo de inteligencia artificial.

La aplicación de esta técnica puede ser de gran importancia ya que permitiría realizar predicciones sobre nuevas ciudades utilizando datos con los que ya se contaba anteriormente. Además permitiría analizar si las distintas ciudades comparten una estructura comercial similar, pudiendo utilizarse con bastante confianza para predecir sobre nuevas; o si, por el contrario cada ciudad posee una estructura distinta y más específica con respecto a otras.

Al igual que con las predicciones que se realizaban a nivel local, estas podrán ser evaluadas utilizando el MRR.

Técnicas y herramientas

En este apartado se tratarán las distintas técnicas y herramientas utilizadas durante el desarrollo del proyecto.

4.1. Herramientas de gestión de proyectos

Para la planificación del proyecto se ha buscado una herramienta que soporte los elementos característicos de un desarrollo ágil como SCRUM permitiendo la creación de distintas tareas y su gestión en el tiempo de desarrollo de la aplicación.

Inicialmente se optó por Zenhub, aunque mientras se estaba desarrollando el proyecto esta pasó a requerir una licencia de pago para su uso, por lo que se sustituyó esta por Zube.

Zenhub

Zenhub [45] se trata de una herramienta de gestión de proyectos basada en las metodologías ágiles, por lo que cuenta con funcionalidades que facilitan la creación de tareas, así como su gestión. Además de crear tareas nos permite asignar a estas un *Sprint*, puntos de poker (utilizados en SCRUM) o poder definir aquellas tareas que lo requieran como *Epics* para diferenciarlas de las otras.

Un punto importante para su elección inicial fue que está integrada con *GitHub*, por lo que facilita la gestión de tareas al hacerla directamente desde el propio repositorio.

Zube

Una vez Zenhub pasó a ser una herramienta de pago, se optó por el uso de Zube [46]. Esta cuenta con muchos de los elementos que Zenhub también tiene. Permite definir tareas y gestionarlas mediante un tablero *Kanban*, colocando las tareas en un área u otra en función de su estado (Backlog, Ready, In Progress,...).

4.2. Lenguajes de programación

Una elección bastante significativa para el proyecto será el lenguaje de programación empleado para su desarrollo.

Python

Python [36] es un lenguaje interpretado de alto nivel bastante utilizado en ámbitos como el *Machine Learning*. Además de lo anterior, cuenta con multitud de librerías de acceso abierto desarrolladas por los propios usuarios y/o la comunidad científica, lo cual es de gran utilidad en muchos aspectos.. En su elección también influye que es uno de los lenguajes que más hemos utilizado durante la carrera.

JavaScript

Al igual que Python, JavaScript [34] es un lenguaje interpretado, pero este es utilizado por los navegadores para poder crear páginas web dinámicas. También cuenta con diversas librerías con funcionalidades que permiten manejar el DOM, hacer distintas visualizaciones, entre otras. Este lenguaje será de gran importancia en el apartado web del proyecto.

4.3. Base de datos

Dada la naturaleza del proyecto y los datos que se manejarán, una base de datos no relacional puede dar ciertas facilidades en el manejo de estos. También cabe destacar que la información tomará forma de grafo y se tratará usando técnicas propias de la ciencia de redes, por lo que estas necesidades tomarán gran importancia en la decisión de la base de datos.

Neo4j

Neo4j [5] es de una base de datos no relacional que pertenece a un nuevo paradigma en las bases de datos, la orientación a grafos, y está desarrollada con Java. Esta es utilizada por grandes empresas como Intel, Adobe, AstraZeneca o incluso la NASA. También cabe destacar su uso en el terreno de la ciencia de datos gracias a *plugins* con utilidades propias de la ciencia de redes.

Cabe mencionar que cuenta con un lenguaje de consultas propio, *Cypher*, con una sintaxis que facilita la obtención de información en un contexto de grafos.

Expuestos los hechos anteriores, Neo4j se parece la elección lógica para un proyecto de nuestras características.

APOC (Awesome Procedures On Cypher)

Como se ha mencionado antes, Neo4j cuenta con *plugins* que facilitan algunas labores en la base de datos. Entre ellos se encuentra APOC [28], que tiene tanto utilidades un tanto más generales, así como algunas más específicas, como por ejemplo cargar datos directamente de peticiones a una API, que nos será bastante útil en la carga de ubicaciones durante el desarrollo del proyecto.

4.4. Librerías

Como se ha mencionado anteriormente, se hará uso de diversas librerías para las labores del proyecto, tanto de Python como de JavaScript.

Driver de Neo4j

Para el manejo de la base de datos de Neo4j a través de Python existen 3 distintos drivers [30]:

Driver Oficial Se trata del driver oficial de Neo4j para Python. Cuenta con cursos para su uso y una extensa documentación.

Py2Neo Es un driver creado por la comunidad de Neo4j con una una intefaz sencilla. Lamentablemente ya no recibe soporte para las últimas versiones de Neo4j.

Neomodel Un driver alternativo al oficial que ofrece un OGM (Object Graph Mapper), similar a los ORMs de otras bases de datos; además de integración con el framework web *Django*.

Dado que Neo4j es una herramienta nueva, que requiere de un proceso de aprendizaje, se ha optado por el driver oficial [29] por su simple uso y la gran cantidad de documentación existente. Se ha desestimado Py2Neo puesto que ya no recibe soporte; y en el caso de Neomodel, las funcionalidades que trae no aportan una ventaja respecto al driver oficial, puesto que en primer lugar no utilizaremos Django, sino Flask para la parte web del proyecto; y en cuanto al OGM que provee, este no nos es necesario puesto que no requeriremos de las ventajas que este nos podría aportar.

OSMPythonTools

OSMPythonTools [21] se trata de una librería que facilita el acceso a la información de los servicios de *Open Street Map* mediante una interfaz simple.

Flask

Flask [13] se trata de un framework de desarrollo web para Python. Está caracterizado por se ligero y flexible, además de contar con librerías que expanden sus funcionalidades. Permite el uso de distintas bases de datos además de contar con un motor de plantillas llamado *Jinja2* para el renderizado de páginas web.

Se ha escogido este framework frente a otros debido a su simplicidad y fácil uso, además cubre todas las necesidades del proyecto. Otro punto significativo en su elección es que ya se había trabajado con él durante la carrera en la asignatura de *Diseño y mantenimiento del Software*.

Leaflet.js

Se trata de una librería de código abierto de JavaScript que permite la visualización de mapas interactivos en páginas web [15]. Para sus mapas puede utilizar información extraída de *OpenStreetMap* para hacer las visualizaciones. Nos servirá para mostrar las distintas ubicaciones que almacenemos en la base de datos en la web.

Vis.js

Es una librería de JavaScript cuyo objetivo es realizar visualizaciones interactivas de grafos en la web [32]. Permite personalizar las visualizaciones con distintas configuraciones. Con esta podremos mostrar la información de la base de datos en forma de grafo en la forma que se haría desde el punto de vista de la ciencia de redes.

Bootstrap 5

Se trata de un framework que se suele utilizar para la creación de interfaces web *responsive* [26]. Cuenta con una extensa documentación y ejemplos para su uso. Facilita el diseño de páginas web ofreciendo componentes reutilizables pudiendo utilizarse directamente en las plantillas HTML.

Scikit-Learn

Scikit-Learn es una librería de código abierto de Python que provee herramientas y algoritmos de aprendizaje automático ampliamente utilizada en este ámbito [1]. En el caso de este trabajo se utilizará para crear los modelos de *Random Forest* con los que se hará el sistema de recomendación.

4.5. APIs

Una parte importante de este proyecto será la información de las ubicaciones de las ciudades escogidas para el proyecto. Para ello se obtendrán mediante APIs de información geográfica, en este caso se utilizará OpenStreetMap para este propósito.

OpenStreetMap es un proyecto abierto y colaborativo que cuenta con información geográfica recopilada por los propios usuarios para la visualización de mapas, rutas de navegación y demás [20].

Para este proyecto se utilizarán las siguientes APIs de este proyecto.

Overpass

Se trata de una de las APIs que componen el proyecto de OpenStreetMap, siendo esta solo de lectura de datos [22, 6]. Está optimizada para las operaciones de lectura, contando con un lenguaje propio de consultas llamado *Overpass QL*. Además introduce algunas nuevas estructuras de datos con

respecto a OpenStreetMap, como es el caso de las áreas, facilitando el acceso a la información en base a regiones.

Nominatim

Nominatim es un motor de búsqueda que forma parte de OpenStreetMap. Sus funcionalidades están centradas en la geolocalización en base a direcciones, nombres de ubicaciones y coordenadas [19]. Cuenta con una API propia que será de utilidad para encontrar las áreas de las distintas ciudades con las que se trabajarán en el proyecto.

4.6. Otros

Además de todas las herramientas anteriormente mencionadas también se ha utilizado para facilitar el uso y despliegue de la aplicación.

Docker

Docker es una plataforma de código abierto utilizada para facilitar el despliegue de aplicaciones y servicios dentro de lo que se conoce como «contenedores» [8]. Estos son capaces de contener todas las dependencias de la aplicación de forma que se pueda utilizar en cualquier equipo usando docker.

Heroku

Heroku es una plataforma que permite desplegar aplicaciones web en la nube de forma gratuita [9]. Cuenta con soporte para distintos lenguajes de programación, entre ellos Python. Nos permitirá desplegar la aplicación desarrollada en este proyecto de forma que su acceso sea más fácil.

Aspectos relevantes del desarrollo del proyecto

5.1. Carga y almacenamiento de ubicaciones

El primer paso del desarrollo del proyecto consiste en el almacenamiento de las ubicaciones obtenidas desde un servicio de geolocación como *Open Street Map* [20]. La elección de este sobre otras alternativas viene motivada debido principalmente a que se trata de un proyecto completamente abierto sin ninguna restricción monetaria sobre la extracción de datos, además es mantenido por la comunidad proporcionando documentación sobre el uso y la estructura de datos que se manejan.

Para la obtención de las ubicaciones se realizarían peticiones a la API de Overpass [22], la cual pertenece al proyecto de Open Street Map. Esta es la que se suele utilizar para labores de lectura de datos.

Carga inicial de ubicaciones

Inicialmente se consideró el cargar las ubicaciones de distintas capitales de Europa, incluyéndose entre estas Madrid, París, Roma, Londres, Berlín y Amsterdam. Dado que Open Street Map cuenta con un sistema de etiquetado con formato *clave-valor* sobre los elementos del su modelo de datos [23], se decidió trabajar únicamente con aquellos datos con clave «amenity» [17]. Esta clave se suele utilizar para cubrir diversos establecimientos públicos, servicios y negocios, por lo que se consideró adecuada para los objetivos buscados en el proyecto.

Para introducir las ubicaciones en la base de datos se optó inicialmente por usar la librería *OSMPythonTools* [21], que provee una interfaz sencilla con la que hacer peticiones a la API. Debido a que el proceso conllevaba cierto tiempo, se empleó una alternativa con el plugin *APOC* [28], que permite cargar datos de la respuesta de una petición HTTP o un fichero JSON.

Una vez el proceso de carga se terminó, contábamos con un total de unos 280.000 nodos y 443 distintos valores de «amenity».

Ciudad	**Número de nodos**
Madrid	27.117
París	54.048
Berlín	82.900
Londres	84.558
Roma	16.675
Amsterdam	13.214

Tabla 5.1: Nodos por ciudad en la primera carga de datos

Al analizar los datos nos percatamos de que muchas «amenities» tenían fallos ortográficos o poseían un significado similar a otros. Este problema se deriva de que las distintas claves de *Open Street Map* no cuentan con un diccionario predefinido de posibles valores, sino que son los usuarios que crean las ubicaciones los que escogen el valor de estas, estén registradas anteriormente o no.

Para resolver este problema se intentaron aplicar algoritmos de distancia de cadenas como Jaro-Winkler [41] o Damerau-Levenshtei [39] con el objetivo de unificar valores de «amenity». Esta solución concluyó con que solo a partir de un 95 % de similitud se podrían juntar etiquetas con relativa precisión, aunque esta operación tendría que hacerse con supervisión para evitar posibles errores.

Otra solución que se buscó fue la de utilizar la información de una página auxiliar de *Open Street Map* que cuenta con estadísticas de los valores de las distintas etiquetas. Se intentó unificar las etiquetas a solo aquellas consideradas como «oficiales», siendo estas las que cuentan con una página dentro de la wiki de *Open Street Map* [17].Para ello se utilizó una API asociada a Open Street Map llamada TagInfo [16]. Esta técnica se acabó

desestimando debido a que muchas de las categorías con más aparición entre las ubicaciones cargadas no contaban con página en la wiki.

Posteriormente se descubrió que gran cantidad de los nodos que estaban cargados en la base de datos pertenecían a mobiliario urbano (bancos, aparcamientos, papeleras, fuentes...), por lo que se consideró su eliminación debido a que estaban representados en la base de datos y podían dificultar la identificación de interacciones entre categorías comerciales. No obstante, en una primera aproximación, se optó por mantenerlos para tratar de no sesgar los datos. Lo único que se hizo fue eliminar los datos de aquellos nodos que contaban con un valor de *amenity* auxiliar del modelo de datos de *Open Street Map* (Yes, No, Fixme...) debido a que no contaban con ningún significado comercial o similar.

Enlazado de nodos

Mientras se encontraba una solución a los problemas enumerados anteriormente se decidió continuar con el enlazado de los nodos en la base de datos. Esto consistía en crear enlaces entre aquellos nodos que estuvieran en a una distancia geodésica de 100 metros. Para hacer esto se dotaron a los nodos con atributos tipo «Point», creados a partir de la latitud y longitud de cada una de las ubicaciones, ya que estos eran valores obligatorios en los nodos de *Open Street Map*.

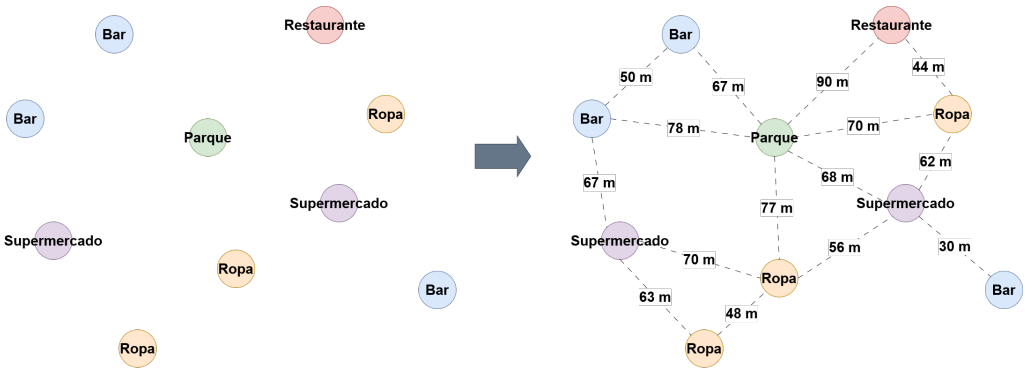

Figura 5.1: Ejemplo de creación de enlaces por proximidad

Una vez dotados a los nodos de estos atributos se crearon los enlaces entre los nodos con tal proximidad usando utilidades que el lenguaje de consultas Cypher provee para manejar distancias y coordenadas. Uno de los problemas de Neo4j es que posee es que solo permite crear enlaces unidireccionales. Si bien esto al principio resultaba problemático puesto que se creaban enlaces

dobles entre cada par de nodos duplicando el número necesario de relaciones, al final se optó por crear un único enlace por par de nodos teniendo en consideración que habría que obviar la dirección en las consultas que se hagan a la base de datos sobre las ubicaciones, reduciendo así el número de aristas del grafo.

Tras finalizar este proceso se completó para todas las ciudades, se saldó el número total de enlaces de proximidad en 5.712.246. Dados los resultados anteriores se consideró que el número de conexiones era bastante superior al esperado y se desestimó el continuar con las ciudades actuales debido al esfuerzo computacional que conllevaría su procesamiento.

Segunda carga de nodos

Una vez vistos los resultados aportados por la elección de las ciudades anteriores se decidió utilizar otras nuevas con un tamaño inferior. Se eligieron Barcelona, Bilbao, Logroño, Oviedo, Santander, Zaragoza, Valladolid, Sevilla, Valencia y Madrid como primera aproximación, con intención de descartar alguna en caso de que se contara con un número muy elevado de localizaciones comerciales.

Ciudad	**Número de nodos**
Barcelona	24.860
Madrid	27.186
Sevilla	6.323
Zaragoza	6.384
Oviedo	1.983
Valladolid	3.034
Bilbao	4.352
Valencia	8.154
Logroño	1.363
Santander	3.038

Tabla 5.2: Nodos iniciales por ciudad en la segunda carga de datos

Tras el análisis de las nuevas ciudades reducimos estas a solo 3: Sevilla, Zaragoza y Valencia, para evitar incurrir en el mismo problema que hemos visto anteriormente, centrándonos en alcanzar los objetivos propuestos para el proyecto con estas ciudades antes de incluir otras nuevas.

Una vez determinadas las ciudades con las que trabajar se procedió a realizar el enlazado de nodos como se hizo anteriormente, dándonos un número manejable de relaciones de proximidad, por lo que se continuó con la creación de las redes de interacción entre categorías.

Interacción entre categorías

Tras haber creado la red de ubicaciones comerciales para cada ciudad, en la que los nodos son los emplazamientos comerciales georreferenciados, el siguiente paso sería el de ver la interacción de las categorías por ciudad. Esta tomaría forma similar a una matriz de adyacencia siendo cada componente el número de veces que los nodos de una categoría poseen enlaces de proximidad con nodos de la misma u otra categoría.

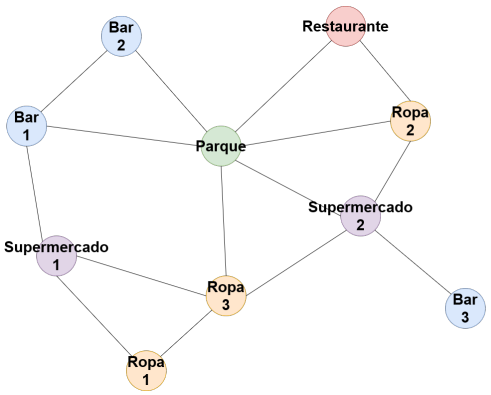

	Bar	Parque	Ropa	Supermercado	Restaurante
Bar	1	2	1	2	0
Parque	2	0	2	1	1
Ropa	1	2	0	4	1
Supermercado	2	1	4	0	0
Restaurante	0	1	1	0	0

Figura 5.2: Ejemplo de interacción entre categorías

Neo4j nos permite obtener mediante consultas la información que contendrían estas matrices de categorías, solo que en una estructura tabular en lugar de matricial, por lo que habría que transformar los datos a una matriz. Un problema que se nos presenta es que en la base de datos no podemos almacenar matrices, ya que Neo4j no soporta este tipo de estructuras. Además, vimos posteriormente que resultaría complicado hacer consultas orientadas a obtener las distintas posiciones de esa matriz.

Se intentó buscar alguna forma en la que almacenar los datos de las categorías además de herramientas para operar con ellos en los *plugins* que Neo4j tiene, especialmente GDS (Graph Data Science) [27] por razones obvias. Tras realizar búsquedas en la documentación de dichos *plugins*, así como hacer distintos cursos oficiales [7] que se ofrecen de forma gratuita no se encontró ninguna utilidad que nos sirviera.

Para solventar el problema de la representación de la matriz de categorías se pensó esta como un grafo pesado con enlaces no dirigidos, estructura que Neo4J maneja adecuadamente. Para ello, se crearán nodos «Categoría» que contarán con atributos con el nombre de la categoría, la ciudad a la que pertenecen y el número de nodos con los que cuenta para dicha ciudad. En cuanto a los enlaces estos serían no dirigidos (dentro de las limitaciones de Neo4j) con un atributo representativo del número de interacciones entre categorías. Este grafo también contaría con autoenlaces para almacenar la interacción de una categoría consigo misma.

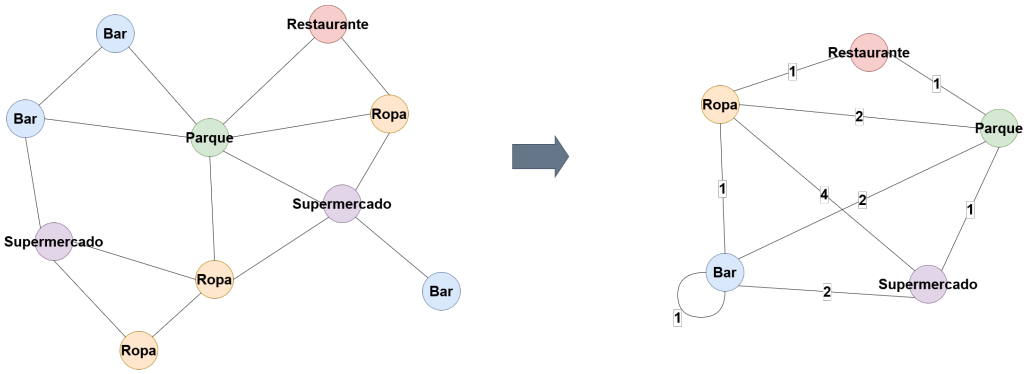

Figura 5.3: Ejemplo de red de categorías

Un problema de esta representación es que normalmente conlleva a crear grafos totalmente conectados y por tanto con un número elevado de enlaces. Para solventar esta posible desventaja, si bien se creó por defecto un enlace entre cada par de categorías (incluso si no interactuaban entre ellas), en estos casos se les asignó un peso de la interacción igual a cero. De esta forma se podrán almacenar los coeficientes que nos proporcionen los distintos métodos a aplicar en un atributo del enlace pese a que no exista interacción.

Aplicación del método *Permutation*

Una vez obtenidas las redes de categorías para cada ciudad tocaría aplicar unos de los métodos con los que obtendríamos métricas con las que hacer recomendaciones. En este caso el método *Permutation*.

Este método consiste en, sobre la red de ubicaciones de cada ciudad, mantener su estructura (nodos y enlaces) pero permutando las categorías de cada nodo [10, 31]. Una vez permutados se volvería a crear la red de categorías y guardarla. Esto se haría multitud de iteraciones haciendo así una simulación de Monte Carlo [35]. Inicialmente el número de simulaciones

que se realizarían sería de 10.000, pero una vez observado el tiempo que conlleva el realizar cada una se redujo a 1000. Todo lo anterior se hizo modificando la red desde Neo4j.

Otra vez más se nos planteó el problema de cómo almacenar la red de categorías de cada iteración de este método, ya que crear una nueva red con nuevos nodos y enlaces supondría una gran carga en cuestión de almacenamiento en la base de datos. Como solución se aprovechó el hecho de que la red de categorías constituye un grafo completamente conectado, almacenando dentro de las propiedades de los enlaces una lista que contenga la interacción entre cada par de categorías en cada iteración del método.

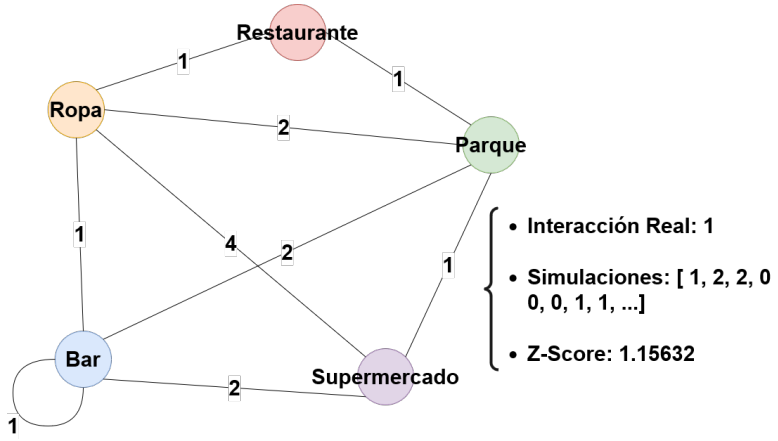

Figura 5.4: Representación de las simulaciones del método *Permutation*

Aplicación de cálculo de coeficientes de Jensen

El siguiente paso sería el cálculo de los coeficientes de Jensen. El problema que presenta Jensen viene en relación con el almacenamiento de los coeficientes de interacción. Dado que los coeficientes no son simétricos i.e. $M_{AB} \neq M_{BA}$ no podemos utilizar los enlaces de anteriores métodos o de la red de interacción para almacenar estos coeficientes, ya que estos se usaban como si fuesen no dirigidos. Para solventar esto se recurrió a crear nuevos enlaces dirigidos con una etiqueta distinta, y a almacenar como atributos de estos enlaces los coeficientes de Jensen. Para cada par de categorías contaríamos con dos enlaces con distinta dirección entre cada nodo categoría.

Si bien lo anterior funcionaba, lo cierto es que aumentaba significativamente el número de enlaces presentes en la base de datos.

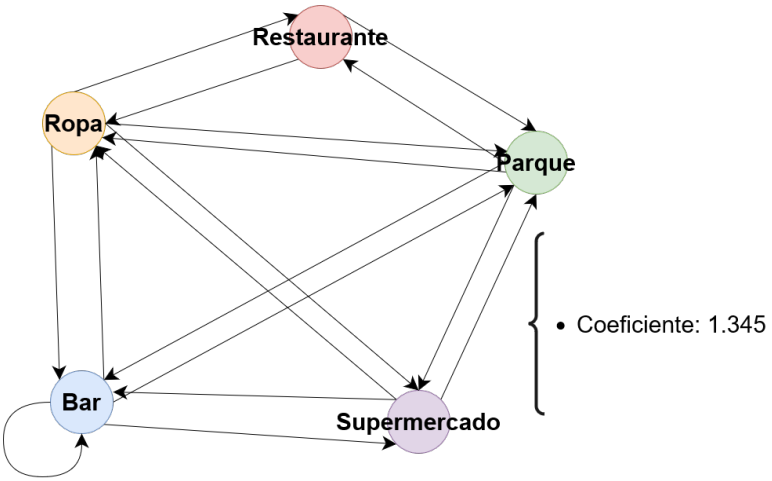

Figura 5.5: Representación de almacenamiento de coeficientes de Jensen en la base de datos

Aplicación del método *Rewiring*

En paralelo a la realización del método de *Permutation*, se pensó en cómo implementar el método de Rewiring en Neo4J, teniendo en cuenta tanto sus funcionalidades disponibles como sus limitaciones.

El método del *Rewiring* funciona de la siguiente manera, dada la red de ubicaciones de una ciudad, conserva la posición de los nodos, su categoría comercial y su grado (número de enlaces), aleatorizando las conexiones, i.e., mantiene el grado pero cambia quién se une con quién. Esto constituye una variante del *Configuration Model* [37], método que a partir de unos nodos y su grado crea redes aletorias, pero con una diferencia, *Rewiring* no permite autoenlaces ni enlaces múltiples [31]. Esto lejos de ser algo banal nos plantea un problema, puesto que la creación de enlaces aleatorios cumpliendo la restricción del grado de los nodos puede llevar a casos donde se requiera de autoenlaces para cumplirse. Además, al igual que en *Permutation* se tendrían que realizar 1.000 simulaciones.

Expuesto lo anterior se desestimó la posibilidad de hacer esto desde Neo4j, requiriendo de un entorno que nos aporte más flexibilidad en las operaciones como el que nos pueda proporcionar un lenguaje de programación. Se hicieron unos prototipos de *Rewiring* desde Python creando redes con distinto número de nodos y grados, así como creando pruebas para comprobar su correcto funcionamiento. Esto se haría al mismo tiempo que el otro

método(Permutation), priorizando más este último debido a que es más sencillo de realizar y menos costoso computacionalmente.

Análisis de los resultados de los métodos

Tras la finalización del método *Permutation* se procedió a obtener ciertas estadísticas de los resultados de este método. En primer lugar se calcularía la media, desviación típica y Z-Scores; además de los percentiles 97.5 y 2.5 para cada interacción entre categorías. Con estas medidas podríamos obtener las relaciones significativas entre categorías, siendo estas aquellas cuyo valor real se encuentre por encima del percentil 97.5 o por debajo del 2.5 de los valores obtenidos mediante simulación [10].

Una vez obtenidas las relaciones más significativas estas mostraban como interacciones más importantes aquellas que incluían elementos del mobiliario urbano (Bancos, papeleras, fuentes, etc.). Si bien inicialmente optamos por no eliminar estos elementos de mobiliario urbano para no sesgar los datos, a la luz de estos resultados vimos que se hacía necesario eliminarlos, ya que nuestro objetivo principal es la identificación de las interacciones comerciales, y la sobrerrepresentación en la base de datos de los elementos de mobiliario urbano nos estaba dificultando su correcta detección. Lo anterior no era información que consideráramos relevante dado que este trabajo está centrado en tiendas y servicios. Esto es debido a que estos elementos están enormemente sobrerepresentados, llegando a ser más de un tercio de la totalidad de ubicaciones que disponíamos. Inicialmente se estimó el no eliminar estas puesto que podía conllevar un sesgo en los datos, pero dados estos resultados quedó claro que suponían un problema y por tanto debían eliminarse.

Otra conclusión que sacamos tras el análisis de los datos fue que la etiqueta «amenity» que utilizábamos para obtener las ubicaciones comerciales no contemplaba a todo el conjunto de tiendas, solo a una parte, existiendo una etiqueta propia de *Open Street Maps* para este propósito, «shop» [18]. Así pues, decidimos eliminar los elementos del mobiliario urbano y a incluir las ubicaciones con etiqueta «shop», y volvimos a iniciar las simulaciones de nuevo.

Antes de comenzar el proceso anterior también se contempló la posibilidad de utilizar datos de otra API de geolocalización gratuita y dejar de usar *Open Street Map*. Entre las que se consideraron tenemos a MapBox [24] y HereMaps [25] con sus planes gratuitos que ofertaban, ya que no se tratan de proyectos abiertos. Después de investigar sobre su modelo de datos se abandonó la posibilidad de su uso puesto que utilizaban múltiples valores

en sus etiquetas, cosa que complicaba enormemente su uso a la hora de estructurar por categorías comerciales, además estaban las limitaciones en sus planes, que podrían suponer un problema en el desarrollo del proyecto.

Tras la inclusión de los nuevos nodos y la eliminación del mobiliario urbano de la base de datos se volvió a comenzar las simulaciones del método *permutation*. Una vez estas comenzaron nos dimos cuenta que estas tardaban un tiempo significativamente mayor que con los datos anteriores, tanto que resultaba inviable proseguir con ellas. Lo anterior es debido a que se incrementó el tiempo que conllevaba obtener la red de categorías para cada simulación i.e. la interacción entre categorías. La causa más probable es que la inclusión de las ubicaciones con etiqueta «shop» prácticamente duplicaba el total de distintas categorías con respecto a los datos anteriores, complicando el recuento de interacciones.

Una vez más se tomó como inviable el continuar con los datos que teníamos en el momento.

Tercera carga de nodos

Dados los hechos anteriores se buscó como solución cargar nodos de ciudades más pequeñas, por lo que se utilizarían datos obtenidos de las ciudades de Castilla y León.

Una vez cargadas la ubicaciones se hizo un análisis y eliminación de los nodos pertenecientes a mobiliario urbano. El análisis mostraba que algunas ciudades tenían un número significativamente bajo del total de ubicaciones, menor que 300, por lo que se eliminaron de la base de datos al considerarse insuficientes. Al finalizar la carga y depurado de nodos contamos con las ciudades de Valladolid, Burgos, Salamanca, León y Palencia.

Ciudad	**Número de nodos**
Palencia	947
León	741
Salamanca	3.224
Valladolid	3.237
Burgos	3.999

Tabla 5.3: Nodos por ciudad en la tercera carga de datos

Obtención de coeficientes

Tras la carga de datos se crearon las redes de interacción para obtener los coeficientes del método *Permutation* además de los de *Jensen*, que no se había probado en los intentos anteriores.

En cuanto a *Permutation* se obró como se hizo anteriormente, con un tiempo por simulación asumible, por lo que se obtuvieron los resultados de las simulaciones sin mayor problema. Una vez se analizaron los datos no se detectó ninguna incoherencia con las relaciones significativas señaladas por el método, dándose los resultados como buenos.

5.2. Desarrollo Web

Uno de los objetivos del proyecto consiste en la creación de una aplicación web que permita visualizar los resultados de los análisis realizados sobre las ciudades que hemos escogido, así como, desde un punto de vista de usuario, poder obtener recomendaciones de categorías comerciales dadas una ubicaciones, que es el propósito último de este trabajo.

Dado que la obtención de los coeficientes de interacción utilizando como base de cálculo Neo4j estaba suponiendo muchas dificultades, se decidió trabajar en paralelo en la creación de la web tras la finalización de la segunda carga de ubicaciones.

Inicialmente se consideraron distintos *frameworks* web con los que crear la aplicación. Dado que el lenguaje de programación elegido para la realización del trabajo es Python tenemos a nuestra disposición *frameworks* como *Flask*, *FastAPI* [3] y *Django* [2].

Finalmente nos decantamos por *Flask*, porque consta de las funcionalidades necesarias para los requisitos del proyecto, cuenta con una curva de aprendizaje menos pronunciada que Django y ya tenía experiencia previa con Flask debido a haberlo utilizado en la asignatura «Diseño y Mantenimiento del Software».

Otro factor a tener en consideración es la falta de experiencia que se tiene de desarrollo web en el momento de la creación de esta aplicación. Esto afecta ya que el aprendizaje de las técnicas y herramientas relacionadas con el desarrollo web tendrán un peso importante durante la creación proyecto.

Para solventar la carencia de habilidades en este respecto se recurrió tanto a tutoriales como a documentación de sitios como MDN [4] para el aprendizaje de HTML, JavaScript y CSS. Otro recurso que se utilizó fue

un curso gratuito impartido por *Neo4j* en el que se enseña como construir aplicaciones web usando el driver de Neo4j para *Python* y *Flask*. Este último, si bien no enseñaba elementos transversales en el desarrollo web, mostraba cómo usar el driver (aunque en estos momentos ya se conocía su uso) y cómo estructurar un proyecto web en Flask.

5.3. Sistema de Recomendación

Una vez obtenidos los coeficientes de interacción entre categorías comerciales de los distintos métodos la siguiente tarea consistiría en calcular los *Quality Indices*. Esto supondría que cada ubicación cargada en la base de datos tenga asociada un valor para categoría y para cada índice de calidad. Una forma de ver esto matricialmente sería una matriz de tamaño (nº de categorías) x (nº de ubicaciones) para cada ciudad. Dado que la base de datos no permite almacenar matrices, una forma equivalente de representarlo sería asociar a cada nodo un «diccionario» siendo las claves las categorías y los valores el índice de calidad, todo esto para cada índice de calidad que utilicemos.

Neo4j nos supone un problema en este aspecto ya que los nodos que utiliza funcionan como un JSON de un único nivel de profundidad, pudiendo ser las claves únicamente *strings* y los valores listas, tipos primitivos o tipos especiales (fechas, puntos de coordenadas...). Esto nos perjudica ya que no sería posible almacenar de una forma simple los indices de calidad. Además cabe mencionar los tiempos de cálculo que, haciéndose desde Neo4j conllevaban un tiempo de unos 3 minutos por nodo. Teniendo en cuenta que contamos con un numero de aproximadamente 12.000 nodos, resultaría inviable.

Dado lo anterior, se decidió cambiar el enfoque del sistema de recomendación. Si inicialmente se buscaba encontrar la categoría más adecuada para unas ubicaciones, ahora sería, dadas una ubicaciones encontrar cuál es la más adecuada para una categoría determinada. Esto haría que en lugar de almacenar los indices de calidad estos se calcularían «al vuelo», bajo demanda.

Esta forma implicaría que no sería posible el uso combinado de índices de calidad mediante un modelo de inteligencia artificial para realizar recomendaciones. No dispondríamos un conjunto de datos con el que poder entrenar y evaluar la precisión del modelo.

Cambiada la aproximación, se prosiguió con los correspondientes cambios en la web para adaptar la funcionalidad.

Tras un tiempo después centrándose en desarrollo web se encontró una posible solución. Para resolver el problema que suponía el almacenamiento, los índices de calidad se almacenarían como un JSON formateado como *string*. Esto pese a parecer una solución pobre nos solventa los problemas que teníamos anteriormente, pudiendo convertir este *string* de vuelta a JSON desde Python y así obtener los valores que buscábamos. Además dentro del plugin APOC [28] de Neo4j, se incluyen procedimientos que facilitan hacer estas conversiones, ya que, aunque Neo4j no permita almacenar «maps» o «diccionarios» en sus nodos, permite utilizarlos en su lenguaje de consultas, Cypher.

En cuanto al problema que suponía el tiempo de computo de los indices de calidad se probó a hacer los cálculos en Python en lugar de Neo4j. Para ello se construirían las matrices de coeficientes de calidad y de promedio de vecinos por categorías mediante consultas a la base de datos y almacenándolas en diccionarios de Python, consiguiendo así un tiempo de acceso constante. Uno de los problemas que presenta esta forma es que los cálculos se deben de hacer nodo a nodo en lugar de hacer actualizaciones masivas cómo se podría hacer desde Neo4j. Para cada nodo además de la información contenida en las matrices de promedio de vecinos por categorías y de coeficientes de calidad se tendría que contar con el número de interacciones con las categorías, cosa que se haría también mediante consultas a la base de datos. Una vez hechos los cálculos de los índices de calidad estos se agruparían en un JSON formateado como *string* y se añadirían a la información del nodo en la base de datos.

Una vez completada la alternativa, esta mostraba buenos resultados temporales, llevando alrededor de 0,1 segundos por nodo.Tras esto contamos con los índices de calidad calculados, permitiéndonos contar con un conjunto de datos sobre el que aplicar un modelo de clasificación. A la vista de esto se decidió trabajar en paralelo con las dos aproximaciones, proporcionándole al usuario dos enfoques de recomendación alternativos: dadas varias ubicaciones encontrar cuál es la mejor para una determinada categoría, y la alternativa, encontrar cuál es la mejor categoría para una ubicación.

Random Forest

Obtenidos los índices de calidad para cada una de la ubicaciones contamos con un conjunto de datos con los que poder entrenar un modelo y hacer recomendaciones en base a ubicación.

La elección de *Random Forest* [43] sobre otros modelos de inteligencia artificial viene motivada por el buen rendimiento que presentan los modelos de tipo *ensemble* sobre otros simples [10, 12]. Estos están compuesto por un conjunto de clasificadores en lugar de solo uno, evitando correlaciones entre árboles, alcanzando en última instancia un buen compromiso *bias*-varianza.

Recomendaciones Locales

Una parte de las recomendaciones que se harían serían utilizando únicamente datos locales, es decir, de la propia ciudad. Esto implica crear un modelo de *Random Forest* para cada ciudad. Las posibles categorías que se pueden recomendar serían exclusivamente aquellas que la propia ciudad posee.

Para poder evaluar el rendimiento real de los modelos se aplicará una técnica común en el ámbito del *machine learning* conocida como validación cruzada. En nuestro caso realizaremos 100 *folds* para los modelos de cada ciudad, para de esta forma evitar distorsionar demasiado la estructura comercial de las ciudades en el conjunto de entrenamiento con los datos utilizados para *test* en cada *fold*.

Tras realizar la validación cruzada se nos arrojan los siguientes resultados:

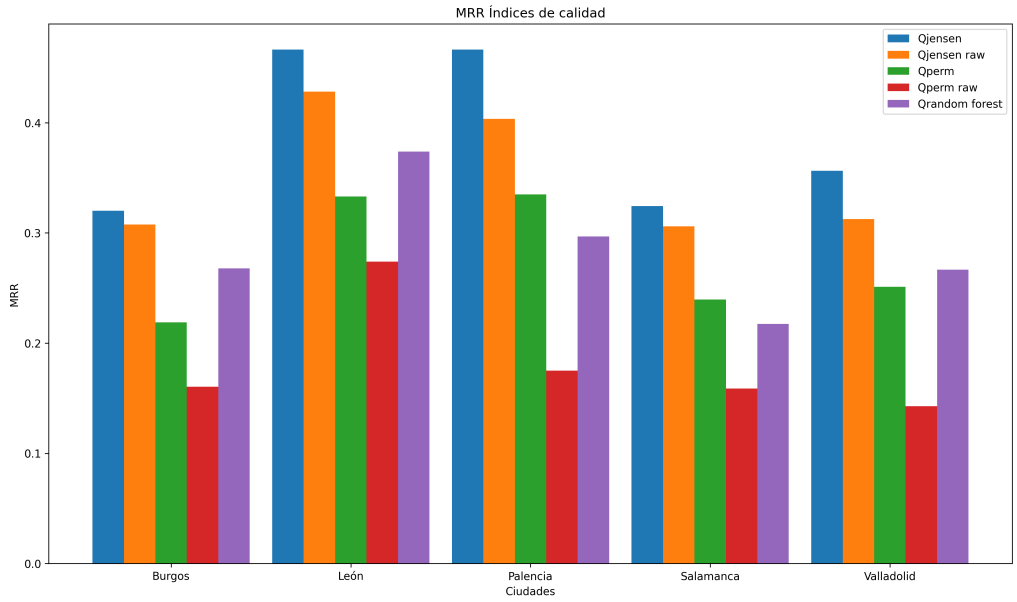

Figura 5.6: *Mean Reciprocal Rank* en las predicciones a nivel local

Como se puede observar, en comparación al resto de índices de calidad los modelos de *Random Forest* no logran superar a todos, viéndose superados en la mayoría de casos por *QJensen* y *QJensen_raw* que parecen ser los que mejor rendimiento ofrecen. Pese a lo anterior, sí que consigue obtener resultados considerables.

Otra conclusión que se puede extraer de los resultados es el impacto del tamaño de la ciudad a la hora de obtener buenas predicciones. León y Palencia son las ciudades que consiguen obtener un MRR más alto que el resto siendo estas dos las regiones más pequeñas, en cuanto a nivel de nodos, de las que contamos. Cabe decir que se aprecia que es más fácil predecir y encontrar patrones cuando se cuenta con una menor diversidad comercial.

Transferencia

A la hora de realizar transferencia de información mediante la utilización de un *Random Forest* se nos presenta un problema con respecto al conjunto de datos a utilizar. Este problema tiene origen en el hecho de que las ciudades tienen conjuntos distintos de categorías, contando con un total de alrededor de 250 categorías si consideramos todas las ciudades. Esto supone que las ubicaciones de una ciudad no van a tener índices de calidad asociados a categorías que no están presentes en dicha ciudad. Además la diferencia

de categorías entre ciudades en algunos casos roza las 100, por lo que de hacerse de esta forma habría muchas ubicaciones con gran parte de índices de calidad desconocidos.

Finalmente se decidió por crear distintos modelos de *Random Forest* para aplicar transferencia. Para ello se utilizaría una ciudad para entrenar (*source*) el modelo y otra sobre la que realizar las predicciones (*target*). Esto supondría tener 20 modelos distintos, puesto que contamos con 5 ciudades y descontamos los modelos que se utilizan para recomendaciones locales. A la hora de obtener el conjunto de datos de cada modelo se utilizarían únicamente las categorías pertenecientes a la intersección entre las categorías de ese par de ciudades, teniendo a su vez que eliminar filas con categoría fuera de esta, así como filtrar columnas con datos pertenecientes a índices de calidad asociados a categorías que no pertenecen a la intersección.

Tras realizar los entrenamientos y predicciones de los distintos modelos, estos nos arrojan los siguientes resultados:

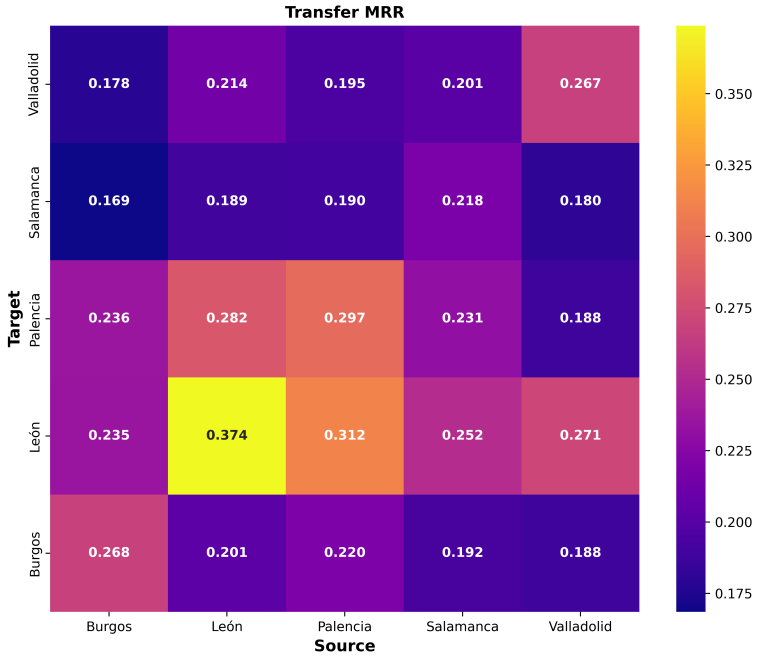

Figura 5.7: *Mean Reciprocal Rank* al aplicar transferencia con *Random Forest*

Trabajos relacionados

6.1. *Knowledge Transfer in Commercial Feature Extraction for the Retail Store Location Problem*

Este artículo es la mayor inspiración detrás de este trabajo, puesto que tanto las técnicas que se han aplicado como la aproximación provienen de este [10].

Al igual que en este artículo, se ha trabajado con ciudades de Castilla y León, aunque no con todas, pese a que no era la intención inicial esta elección de ciudades.

Las principales diferencias con respecto lo realizado en este trabajo consisten en el origen de los datos y las categorías utilizadas. En el artículo los establecimientos comerciales son extraídos desde las Páginas Amarillas de 2017 y posteriormente geolocalizadas mediante APIs. En cuanto a categorías se utilizó 68 posibles valores definidos por *North American Industry Classification for Small business* (NAICS).

Aplicaron los 3 métodos expuestos anteriormente, incluido el *Rewiring* que no se pudo realizar en este trabajo, además de combinarlos mediante *Random Forest*. Obtuvieron los siguientes resultados a nivel local:

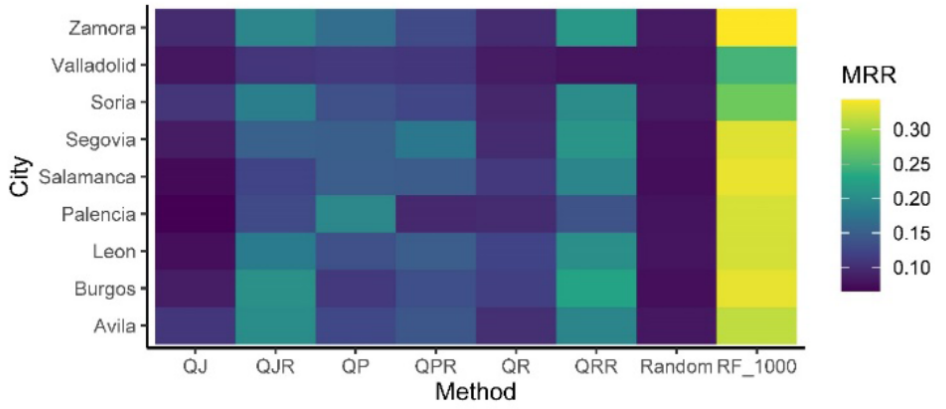

Figura 6.1: *Mean Reciprocal Rank* por método y ciudad

En cuanto a la transferencia puesto que contaban con más ciudades, podían utilizar más combinaciones para probar su rendimiento.

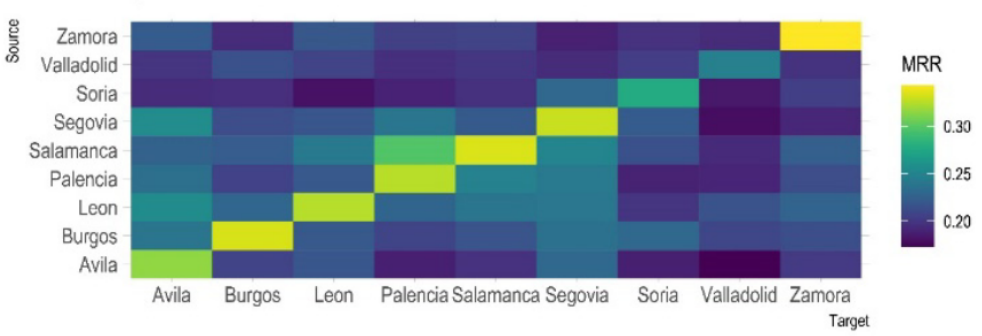

Figura 6.2: *Mean Reciprocal Rank* al utilizar transferencia

En contraste con lo realizado con este trabajo, parece que la inclusión de nuevas ubicaciones pertenecientes a categorías no contempladas por el NAICS ayuda a obtener mejores resultados.

6.2. *Retail Store Location Problem with Multiple Analytical Hierarchy Process of Decision Making*

Este artículo [11] es un ejemplo de otra aproximación al problema de selección de ubicación distinta a la ciencia de redes. En este emplean

lo llamado *Analytical Hierarchy Process* (AHP). Este consiste en definir distintos componentes tanto objetivos como subjetivos y hacer una decisión multicriterio en base a estos. Define 15 criterios agrupados en 5 categorías:

- (M) Costes
  - **M1**: Coste del alquiler.
  - **M2**: Coste del mobiliario.
  - **M3**: Tiempos y condiciones de contratación.
- (R) Competencia
  - **R1**: Poder de la competencia.
  - **R2**: Número de competidores.
  - **R3**: Distancia a la competencia.
- (T) Densidad de tráfico
  - **T1**: Tráfico de vehículos.
  - **T2**: Tráfico de viajeros.
- (F) Característica físicas
  - **F1**: Tamaño de la tienda.
  - **F2**: Aparcamientos.
  - **F3**: Visibilidad.
- (Y) Localización
  - **Y1**: Sobre calle principal.
  - **Y2**: En centro comercial.
  - **Y3**: Cercano a centros de negocio.
  - **Y4**: Cercano a áreas residenciales y sociales.

Si bien este artículo buscaba encontrar las mejores ubicaciones para un determinado negocio en 3 asentamientos, y por tanto, tomando una aproximación distinta a lo realizado en este proyecto, se puede apreciar la gran cantidad de información necesaria para poder estimar la mejor ubicación. Este problema no se presenta en nuestro proyecto, puesto que contando únicamente con las ubicaciones comerciales es capaz de inferir la adecuación de una localización a varias categorías comerciales, no solamente a una.

Conclusiones y Líneas de trabajo futuras

7.1. Conclusiones

En este proyecto se ha conseguido realizar un sistema de recomendación de categorías que puede ser de gran utilidad para todas aquellas personas que estén pensando en abrir un negocio, o simplemente para analizar la estructura comercial de las distintas ciudades. Finalmente la aplicación proporciona dos posibilidades: subconjunto de locales para una categoría e identificar el mejor, y mejor categoría para un local.

Durante el desarrollo han surgido bastantes dificultades que no se preveían inicialmente que han obligado tomar distintas decisiones para llevar el proyecto a cabo. Muchas de estas están relacionadas con las herramientas utilizadas. Si bien el uso de estas nos ha llevado a problemas, cabe destacar que son las mejores opciones disponibles. Desarrollaré en los apartados sucesivos al respecto.

Sobre la base de datos

El uso de Neo4j vino principalmente motivado porque fue una de las herramientas propuestas para el proyecto. Tratándose de una base de datos orientada a grafos parecía ser apropiada para el desarrollo del trabajo, puesto que se han utilizado conceptos y estrategias propias de la ciencia de redes.

Desde el comienzo del proyecto se instó a usar lo máximo posible Neo4j para la mayoría de las etapas del proyecto con objetivo de aprovechar las funcionalidades que nos provee así cómo para justificar su uso de cara al trabajo.

Si bien es cierto que Neo4j hace bastante cómoda la obtención de datos de un grafo, no es tan flexible en otros aspectos. Esto se ha visto en los momentos en los que se buscaba aplicar los métodos de *Rewiring* y *Permutation*, así como el almacenamiento de los coeficientes que estos nos proporcionaban. Esto es así debido a que no dispone de librerías para la realización de cálculos matemáticos más allá de los más básicos, y a su incapacidad de generar y trabajar con matrices.

Cuando se requiere hacer una consulta más allá de lo más básico que se pueda hacer con *Cypher*, el lenguaje de consultas de Neo4j, inevitablemente se tendrá que recurrir a procedimientos del plugin APOC. Esta característica hace que las consultas se vuelvan bastante tediosas y complejas, con varias llamadas a procedimientos de este plugin, dificultando su uso. Las capacidades que nos provee *Cypher* nativo están bastante limitadas sin el uso de este plugin.

Otro problema que plantea la base de datos es el modelo de datos que emplea. Neo4j no cuenta con la flexibilidad que otras bases de datos no relacionales tienen en este aspecto. Esto puede verse cuando se busca almacenar datos anidados en alguna de las entidades (nodos o relaciones), que no pueden almacenarse como una simple propiedad de estas sino que tienen que serializarse de un alguna forma (cómo se ha hecho en este trabajo) o recurrir a crear una nueva entidad relacionada que almacene dichos datos.

En cuanto a la realización de cálculos complejos, también se ha visto que no es recomendable su uso más allá de las operaciones que estamos acostumbrados a realizar en otras bases de datos, puesto que tras intentar hacerlos se ha comprobado que son mucho más lentas de lo esperado. Aunque lo anterior puede que sea consecuencia de la complejidad de las consultas como se comentado anteriormente. Además, en general estas operaciones son realmente difíciles de hacer para un usuario que no cuente con bastante experiencia anterior con esta base de datos.

Sobre conceptos propios de la ciencia de redes tampoco aporta mucha ayuda en ver las entidades de la base de datos cómo se haría desde esta disciplina, puesto que no aporta alguna representaciones utilizadas habitualmente como matrices o el no soporte a relaciones no dirigidas. Además resulta complicado trabajar con datos derivados de grafos para realizar operaciones o cálculos sobre el grafo, especialmente si estos constituyen una entidad propia como se ha hecho en este trabajo con las matrices de interacción y relacionados.

Habiendo expuesto lo anterior, parece que Neo4j no termina de comprometerse totalmente con ninguno de los conceptos en los que se basa,

las bases de datos no relacionales y la ciencia de redes. No cuenta con la flexibilidad de otras bases de datos ni aporta algunos elementos propios de la ciencia de redes. Si alguien fuese a valorarse su uso, como opinión personal diría que debería verse como más próximo a las bases de datos no relacionales que a la ciencia de redes. Tras haber trabajado con ella parece más apropiada para otros contextos, como redes sociales y similares, en lugar de la temática de este trabajo. Además, la amplia mayoría de funcionalidades que ofrece el *plugin Graph Data Science* están relacionadas con aspectos más convencionales de la ciencia de redes, como detección de comunidades, *Random Walk*, medidas de centralidad y etc.

Para finalizar cabe mencionar que se tenían unas expectativas con respecto a Neo4j derivadas del desconocimiento de la herramienta que no se han visto satisfechas. Si bien nos permite almacenar un grafo de forma persistente y operar con el directamente creo que no es competencia de una base de datos la realización de unas operaciones tan complejas como las que se han realizado, teniendo en su lugar que realizarse desde un lenguaje de programación que nos aporte una versatilidad que un lenguaje de consultas no es capaz de dar. Lo anterior sería lo ideal en caso de no contar con limitaciones como la capacidad de la memoria para alojar el grafo o similares, aunque tiene el impedimento de tener que construir el grafo mediante consultas, proceso que lleva tiempo, además de no poder operar directamente sobre el grafo en casos que se requiera hacer modificaciones o borrados ni obtener información tan fácilmente como se hace desde Neo4j mediante consultas de *Cypher*.

Sobre *OpenStreetMap*

OpenStreetMap también se trataba de una de las herramientas propuestas. Si bien la obtención de datos no ha supuesto un problema de por sí ya que al tratarse de un proyecto abierto no ha habido barreras monetarias al respecto, y contar con un lenguaje de consultas propio para la obtención de datos; sí que lo ha habido sobre el contenido de las ubicaciones y su cantidad.

Uno de los problemas que nos ha presentado los datos son los valores de sus etiquetas de categorías. Cómo se ha mencionado en uno de los apartados del trabajo, no existe un diccionario de valores, sino que los usuarios son quienes los asignan. Esto conlleva a que existan gran cantidad de categorías, algunas con múltiples valores, faltas ortográficas y demás que han dificultado ciertas fases del proyecto. Sin duda una de las líneas de mejora de OpenStreetMap sería precisamente que definan una taxonomía

propia que se establezca como estándar, y que todos los usuarios tengan que hacer uso de ella cuando hagan sus contribuciones.

Otro punto a destacar es la diferencia de número de ubicaciones en distintas ciudades, esto lejos de adecuarse a la realidad creo que viene determinado por la falta de cobertura de algunas zonas por parte del proyecto, además de la falta de puesta al día de la información de ciertas ubicaciones. Este tipo de problemas se derivan, sin duda, de que sean los usuarios particulares los que alimentan la herramienta.

Overpass QL, el lenguaje de consultas de esta API, si bien facilita la obtención de datos presenta problemas al obtener datos de ciertas áreas si existen más de una con ese mismo nombre. Tampoco pueden hacerse búsquedas de áreas dentro de áreas, cosa que es problemática al querer operar con determinadas zonas. En este caso planteó problemas al obtener datos de las ciudades finales del proyecto puesto que había más ciudades con ese nombre, por lo que se tuvo que recurrir al número de municipio para obtener sus nodos.

En conclusión se puede decir que, *OpenStreetMap* supone una buena herramienta abierta para la obtención de datos, no sin sus inconvenientes, que probablemente si se hubiese utilizado una API de pago no se presentarían además de probablemente contar con una mejor calidad de datos.

7.2. Líneas de trabajo futuras

Debido a la gran cantidad de imprevistos que nos hemos encontrado durante el proyecto, los cuales se han derivado de su naturaleza de proyecto de investigación más que de desarrollo puro, hay apartados que han acabado con un desarrollo menor a lo esperado inicialmente. Además con los descubrimientos realizados podemos hacer algunas recomendaciones para proyectos similares a este o que busquen continuarlo.

Sobre las categorías de ubicaciones que se han utilizado, tras su empleo se ha llegado a la conclusión de que contar con un número elevado de categorías aumenta exponencialmente el esfuerzo computacional que conlleva la obtención de índices de calidad, así como las recomendaciones, además de contar con algunas que pueden ser redundantes o no relevantes. Lo más adecuado quizás sería emplear alguna forma de normalización de estas que nos permita transformarlas para tener un número más reducido de categorías aunque contemple todos los posibles valores, facilitando la obtención de métricas de calidad. Esto, sin embargo, debería hacerse con cuidado. Si se reducen

las categorías a un número muy pequeño puede empeorar la calidad de los datos que disponemos, puesto que puede que no se capture adecuadamente la diversidad que hay entre categorías, agrupando varias con diferencias importantes entre sí, empeorando también las posibles recomendaciones que se pudieran hacer sobre ellas. Por el otro lado, si se reduce mínimamente las categorías se seguiría teniendo el mismo problema presentado anteriormente, siendo únicamente algo menos grave.

En cuanto a la calidad de los datos que nos ofrece *OpenStreetMap*, como se ha observado en apartados anteriores, presentan problemas sobre los valores de categorías así como la irregularidad en el número de ubicaciones sobre algunas ciudades. Dado lo anterior, sería buena idea emplear APIs de pago que no se han podido utilizar como *Google Maps*, a las que presuponemos una gran calidad de datos. Un punto a tener en consideración en la elección de estas sería el modelo de datos que emplean, especialmente el cómo estructuran las categorías comerciales, puesto que algunas emplean una lista de valores en lugar de un único valor; esto imposibilitaría la aplicación de los métodos de recomendación de este trabajo. De presentarse esto, podría aplicarse la normalización de categorías que se propone en el párrafo anterior para que el uso de los datos fuera factible.

Muchas de las líneas futuras de este proyecto están relacionadas con la aplicación web, debido a las limitaciones temporales y de las herramientas utilizadas. Si bien están definidos roles, ninguno cuenta con permisos o utilidades especiales. Sería de bastante utilidad proveer a los administradores de una herramienta que les permita cargar datos de otras ciudades así como poder examinarlos y realizar los borrados y modificaciones que crean convenientes. Esto requeriría alojar la aplicación web en un sitio con la suficiente capacidad computacional como para aplicar los métodos realizados en este trabajo con objetivo de disponer de nuevas ciudades sobre las que realizar recomendaciones. En cuanto a los usuarios, se les podría dotar de la capacidad de guardar las ubicaciones sobre las que estén interesados, pudiendo acceder a ellas desde su perfil y realizar comparaciones sobre ellas.

En relación a los modelos utilizados para el sistema de recomendación solo se ha empleado *Random Forest*, por lo que podría incluir nuevos modelos que el usuario pueda elegir con cuales realizar las recomendaciones.

El único método de obtención de métricas de calidad que ha faltado por implementar ha sido *Rewiring*. Debido a los problemas que presenta este método no se utilizó en este proyecto, por lo que podría emplearse para desarrollos posteriores. Dada la complejidad que presenta y las dificultades

de Neo4j para operar sobre grafos lo considero prácticamente irrealizable desde este, por lo que debería realizarse desde un lenguaje de programación.

Bibliografía

[1] About us — scikit-learn.org. https://scikit-learn.org/stable/about.html.

[2] Django — djangoproject.com. https://www.djangoproject.com/.

[3] FastAPI — fastapi.tiangolo.com. https://fastapi.tiangolo.com/. [Accessed 09-09-2023].

[4] MDN Web Docs — developer.mozilla.org. https://developer.mozilla.org/es/.

[5] Neo4j graph database & analytics – the leader in graph databases — neo4j.com. https://neo4j.com/.

[6] Overpass API - OpenStreetMap Wiki — wiki.openstreetmap.org. https://wiki.openstreetmap.org/wiki/Overpass_API.

[7] Take the Neo4j Graph Data Science Certification course with Neo4j GraphAcademy — graphacademy.neo4j.com. https://graphacademy.neo4j.com/courses/gds-certification/.

[8] What is a Container? — docker.com. https://www.docker.com/resources/what-container/.

[9] What is Heroku | Heroku — heroku.com. https://www.heroku.com/what. [Accessed 09-09-2023].

[10] Virginia Ahedo, Jose Ignacio Santos, and Jose Manuel Galan. Knowledge transfer in commercial feature extraction for the retail store location problem. *IEEE Access*, 9:132967–132979, 2021.

[11] Hikmet Erbıyık, Selami Özcan, and Kazım Karaboğa. Retail store location selection problem with multiple analytical hierarchy process of decision making an application in turkey. *Procedia - Social and Behavioral Sciences*, 58:1405–1414, 10 2012.

[12] Manuel Fernández-Delgado, Eva Cernadas, Senén Barro, Dinani Amorim, and Amorim Fernández-Delgado. Do we need hundreds of classifiers to solve real world classification problems?, 2014.

[13] Flask. Welcome to Flask; Flask Documentation (2.3.x) — flask.palletsprojects.com. https://flask.palletsprojects.com/en/2.3.x/.

[14] Pablo Jensen. A network-based prediction of retail stores commercial categories and optimal locations, 2006.

[15] Leaflet.js. Leaflet — an open-source JavaScript library for interactive maps — leafletjs.com. https://leafletjs.com/.

[16] Open Street Map. amenity | Keys | OpenStreetMap Taginfo — taginfo.openstreetmap.org. https://taginfo.openstreetmap.org/keys/amenity#overview.

[17] Open Street Map. ES:Key:amenity - OpenStreetMap Wiki — wiki.openstreetmap.org. https://wiki.openstreetmap.org/wiki/ES:Key:amenity.

[18] Open Street Map. Key:shop - OpenStreetMap Wiki — wiki.openstreetmap.org. https://wiki.openstreetmap.org/wiki/Key:shop.

[19] Open Street Map. Nominatim — nominatim.org. https://nominatim.org/.

[20] Open Street Map. OpenStreetMap — openstreetmap.org. https://www.openstreetmap.org/about.

[21] Open Street Map. OSMPythonTools — pypi.org. https://pypi.org/project/OSMPythonTools/.

[22] Open Street Map. Overpass API - OpenStreetMap Wiki — wiki.openstreetmap.org. https://wiki.openstreetmap.org/wiki/Overpass_API.

[23] Open Street Map. Tags - OpenStreetMap Wiki — wiki.openstreetmap.org. https://wiki.openstreetmap.org/wiki/Tags.

[24] MapBox. Maps, geocoding, and navigation APIs & SDKs | Mapbox — mapbox.com. https://www.mapbox.com/.

[25] HERE Maps. HERE WeGo | Maps & Navigation | Applications | HERE — here.com. https://www.here.com/products/wego.

[26] Jacob Thornton Mark Otto and Bootstrap contributors. Bootstrap — getbootstrap.com. https://getbootstrap.com/.

[27] neo4j. Graph algorithms - Neo4j Graph Data Science — neo4j.com. https://neo4j.com/docs/graph-data-science/current/algorithms/.

[28] Neo4j. Neo4j APOC Library - Developer Guides — neo4j.com. https://neo4j.com/developer/neo4j-apoc/.

[29] Neo4j. Neo4j Python Driver 5.11; Neo4j Python Driver 5.11 — neo4j.com. https://neo4j.com/docs/api/python-driver/current/.

[30] Neo4j. Using Neo4j from Python - Developer Guides — neo4j.com. https://neo4j.com/developer/python/.

[31] Rosa María Sánchez-Saiz, Virginia Ahedo, José Ignacio Santos, Sergio Gómez, and José Manuel Galán. Identification of robust retailing location patterns with complex network approaches. *Complex and Intelligent Systems*, 8:83–106, 2 2022.

[32] VisJS. vis.js — visjs.org. https://visjs.org/.

[33] Wikipedia. Ciencia de redes — wikipedia, la enciclopedia libre, 2023. [Internet; descargado 16-junio-2023].

[34] Wikipedia. Javascript — wikipedia, la enciclopedia libre, 2023.

[35] Wikipedia. Método de montecarlo — wikipedia, la enciclopedia libre, 2023. [Internet; descargado 16-enero-2023].

[36] Wikipedia. Python — wikipedia, la enciclopedia libre, 2023.

[37] Wikipedia contributors. Configuration model — Wikipedia, the free encyclopedia. https://en.wikipedia.org/w/index.php?title=Configuration_model&oldid=1097175572, 2022. [Online; accessed 16-June-2023].

[38] Wikipedia contributors. Mean reciprocal rank — Wikipedia, the free encyclopedia. https://en.wikipedia.org/w/index.php?title=Mean_reciprocal_rank&oldid=1107032139, 2022.

[39] Wikipedia contributors. Damerau–levenshtein distance — Wikipedia, the free encyclopedia. https://en.wikipedia.org/w/index.php?title=Damerau%E2%80%93Levenshtein_distance&oldid=1165924193, 2023. [Online; accessed 9-September-2023].

[40] Wikipedia contributors. Graph theory — Wikipedia, the free encyclopedia. https://en.wikipedia.org/w/index.php?title=Graph_theory&oldid=1171835383, 2023.

[41] Wikipedia contributors. Jaro–winkler distance — Wikipedia, the free encyclopedia. https://en.wikipedia.org/w/index.php?title=Jaro%E2%80%93Winkler_distance&oldid=1156974132, 2023.

[42] Wikipedia contributors. Null model — Wikipedia, the free encyclopedia. https://en.wikipedia.org/w/index.php?title=Null_model&oldid=1169838323, 2023.

[43] Wikipedia contributors. Random forest — Wikipedia, the free encyclopedia. https://en.wikipedia.org/w/index.php?title=Random_forest&oldid=1171490126, 2023.

[44] Wikipedia contributors. Transfer learning — Wikipedia, the free encyclopedia. https://en.wikipedia.org/w/index.php?title=Transfer_learning&oldid=1167162322, 2023.

[45] ZenHub. Zenhub - Productivity Management for Software Teams — zenhub.com. https://www.zenhub.com/.

[46] Zube. Zube | Agile project management with a seamless GitHub integration — zube.io. https://zube.io/.